

Análise e Predição de Satisfação de Usuários em Jogos Digitais na Plataforma Steam

Eduardo Maciel Alexandre¹, Josenilton Ferreira da Silva Junior¹
Leandro Marcio Elias Da Silva¹, Sthefany Barboza de Lima¹

¹Instituto de Computação – Universidade Federal de Alagoas (UFAL)
Maceió – AL – Brazil

{ema2, jfsj2, lmes, sbl2}@ic.ufal.br

Abstract. *This report presents a Data Science project focused on analyzing and predicting user satisfaction in digital games on the Steam platform. Using a stratified sample of 200,000 reviews from a base of 41 million records, hypotheses regarding playtime, price, and monetization models were evaluated. Logistic Regression, Random Forest, and XGBoost Classifier models were trained and compared. XGBoost achieved the best performance (F1-Score of 92.4% and AUC-ROC of 70.4%), revealing that accumulated playtime and final price are the most determining factors for user satisfaction.*

Resumo. *Este relatório apresenta um projeto de Ciência de Dados focado na análise e predição da satisfação de usuários em jogos digitais na plataforma Steam. Utilizando uma amostra estratificada de 200.000 avaliações a partir de uma base de 41 milhões de registros, foram avaliadas hipóteses sobre tempo de jogo, preço e modelo de monetização. Modelos de Regressão Logística, Random Forest e XGBoost Classifier foram treinados e comparados. O XGBoost obteve o melhor desempenho (F1-Score de 92,4% e AUC-ROC de 70,4%), revelando que o tempo de jogo acumulado e o preço final são os fatores mais determinantes para a satisfação do usuário.*

1. Aplicação

1.1. Contextualização e Relevância do Problema

A indústria global de jogos digitais consolidou-se como um dos setores de entretenimento de maior crescimento econômico da última década, e dentro desse ecossistema a plataforma Steam, desenvolvida e mantida pela Valve Corporation, ocupa posição de destaque absoluto no mercado de distribuição digital para computadores pessoais, reunindo mais de 130.000 títulos e dezenas de milhões de usuários registrados ao redor do mundo. A dimensão da plataforma enquanto objeto de estudo científico é notável porque ela disponibiliza publicamente um volume expressivo de dados comportamentais — incluindo histórico de compras, tempo de jogo por título e avaliações binárias —, tornando-a um laboratório natural privilegiado para estudos de comportamento do consumidor e análise de satisfação em larga escala.

O problema central que motiva este projeto emerge de uma tensão estrutural bem documentada: o crescente desalinhamento entre a oferta de produtos e a

satisfação efetiva dos consumidores. Pesquisas apontam que aproximadamente 37% dos jogos adquiridos na Steam nunca chegam a ser iniciados pelos compradores, o que representa evidência robusta de que os mecanismos de recomendação vigentes falham sistematicamente em conectar usuários a títulos que gerarão engajamento genuíno. Essa falha é economicamente custosa para ambos os lados: desenvolvedores perdem a oportunidade de converter experiência em recomendação positiva, enquanto usuários dilapidam recursos financeiros em aquisições que não proporcionam o valor esperado. Para além do impacto financeiro direto, as avaliações na Steam funcionam como sinal de qualidade de alta relevância algorítmica, sendo determinantes para a visibilidade orgânica de um título — e um jogo que acumula avaliações negativas enfrenta um ciclo de retroalimentação que reduz sua exposição e, conseqüentemente, suas vendas futuras.

1.2. Definição Formal do Problema e Objetivos

O problema é formalmente definido como **classificação binária supervisionada**: dada a associação entre o perfil comportamental de um usuário e as características objetivas de um jogo, o modelo deve prever $is_recommended \in \{0, 1\}$, onde 1 representa satisfação e 0 representa insatisfação. O vetor de atributos de entrada integra características do produto (preço, tags de gênero), do comportamento do usuário naquele título específico (horas jogadas) e do perfil agregado do usuário na plataforma (volume total de compras, número de avaliações publicadas).

Para investigar esse problema, o projeto foi organizado em torno de quatro objetivos complementares. O primeiro, de caráter **confirmatório**, consiste em testar empiricamente as hipóteses formuladas sobre os fatores determinantes da satisfação — H1 sobre tempo de jogo, H2 sobre preço e descontos, e H3 sobre o modelo de monetização — por meio de análise estatística descritiva e testes de hipótese formais. O segundo objetivo, de caráter **preditivo**, é construir, treinar e comparar três modelos de aprendizado supervisionado de complexidades crescentes: Regressão Logística como baseline interpretável, Random Forest como modelo ensemble de médio-alta complexidade e XGBoost como modelo de gradient boosting de alta performance. O terceiro objetivo, **interpretativo**, busca quantificar o efeito de cada variável sobre a probabilidade de satisfação por meio de Feature Importance e valores SHAP (SHapley Additive exPlanations). O quarto, de caráter **prescritivo**, consiste em traduzir os achados quantitativos em recomendações gerenciais concretas para precificação, desenvolvimento de produto e refinamento dos sistemas de recomendação.

2. Base de Dados

2.1. Origem, Estrutura e Estratégia de Amostragem

O dataset *Game Recommendations on Steam* (Kaggle/antonkozyriev) foi coletado diretamente da API pública da Steam Store e da SteamSpy, sendo composto por quatro arquivos que representam entidades relacionais distintas: **games.csv** concentra os atributos comerciais de cada título; **users.csv** registra informações de perfis públicos de usuários; **recommendations.csv**, com 41 milhões de avaliações binárias, constitui o núcleo relacional do dataset; e **games_metadata_formatado.json** complementa o primeiro com tags de gênero e descrições textuais.

Dado o volume original de 41 milhões de registros, a execução direta de algoritmos de aprendizado de máquina sobre a base completa seria computacionalmente inviável. Adotou-se, portanto, amostragem estratificada por `is_recommended` com 200.000 registros, solução que preserva a proporção de classes da população original e garante que os modelos sejam treinados em condições ecologicamente válidas. Experimentos preliminares com 20.000 registros foram conduzidos para validação rápida do pipeline, e seus resultados são referenciados pontualmente para ilustrar o efeito do tamanho amostral sobre o poder estatístico dos testes. O conjunto final de variáveis analíticas é apresentado na Tabela 1.

Tabela 1. Principais Variáveis Analíticas

Variável	Tipo	Descrição
<code>is_recommended</code>	Binária (0/1)	Target: 1 = recomendação positiva
<code>hours</code>	Numérica contínua	Horas de jogo acumuladas no título avaliado
<code>price_final</code>	Numérica contínua	Preço final do jogo em USD
<code>discount</code>	Numérica (0–100)	Percentual de desconto aplicado
<code>is_free</code>	Binária (0/1)	Indica se o título é gratuito
<code>products / reviews</code>	Numérica inteira	Total de produtos e avaliações do usuário
<code>num_tags</code>	Numérica inteira	Contagem de tags de gênero associadas ao jogo
<code>playtime_category</code>	Categórica (4 níveis)	Faixa de tempo: Baixo Médio Alto Saturação
<code>price_tier</code>	Categórica (4 níveis)	Faixa de preço: Barato Médio Caro Premium

2.2. Pipeline de Pré-processamento

O pipeline de pré-processamento foi estruturado em seis etapas sequenciais. A leitura dos arquivos implementa um mecanismo de *fallback* robusto entre os formatos JSON Lines e JSON convencional, seguida de normalização de colunas para garantir compatibilidade entre versões do dataset. A subamostragem é realizada deliberadamente *antes* dos joins relacionais, evitando a expansão combinatória de registros que ocorreria na ordem inversa. A integração dos quatro arquivos é feita via *left join* a partir de `recommendations.csv`, preservando todas as avaliações mesmo sem correspondência nas tabelas de suporte. O tratamento de valores ausentes diferencia entre variáveis críticas — para as quais se adota remoção completa do registro — e variáveis de perfil (`products`, `reviews`), para as quais a ausência é interpretada como comportamento nulo e imputada por zero.

A etapa de engenharia de atributos merece destaque por seu papel na investigação das hipóteses. A variável `playtime_category` foi criada pela discretização de `hours` em quatro faixas percentílicas (Baixo, Médio, Alto, Saturação), calibradas para capturar os fenômenos comportamentais hipotetizados em H1. A variável `price_tier` foi construída a partir de quebras comercialmente significativas

do mercado de jogos (Barato: < \$10; Médio: \$10–\$30; Caro: \$30–\$60; Premium: > \$60). Ambas as variáveis categóricas foram codificadas via *one-hot encoding* com `drop_first=True` e incorporadas ao vetor de features simultaneamente com suas versões contínuas originais, permitindo que os modelos baseados em árvores capturassem tanto efeitos lineares quanto efeitos de limiar.

3. Análise Estatística e Inferência

3.1. H1 — Tempo de Jogo e Satisfação do Usuário

A primeira hipótese postulava uma relação em forma de U-invertido entre tempo de jogo acumulado e taxa de recomendação positiva: usuários com poucas horas jogadas tenderiam a não recomendar por experiência insuficiente, enquanto usuários com horas excessivas — na faixa de saturação — também apresentariam queda na satisfação por exaustão progressiva com o título. Os dados confirmam **parcialmente** essa hipótese, mas com uma nuance relevante em relação ao que esperávamos.

A categoria Baixo registrou taxa de recomendação de apenas 63,3%, substancialmente inferior às demais e confirmando sem ambiguidade o mecanismo de experiência insuficiente que prevíamos. Esse resultado faz sentido intuitivo: é difícil formar uma avaliação definitiva sobre um jogo com poucas horas de contato, e quando o usuário se sente obrigado a avaliar sem ter explorado o conteúdo, a tendência é um julgamento mais cauteloso ou negativo. A categoria Médio apresentou uma elevação expressiva para 85,7% — um salto de 22,4 pontos percentuais —, confirmando que um engajamento moderado já é suficiente para consolidar uma experiência positiva. A categoria Alto atingiu o pico com 90,3%, reforçando a ideia de que jogadores comprometidos com um título tendem a ser seus maiores entusiastas.

O ponto mais interessante, porém, está na categoria Saturação: em vez da queda acentuada que hipotetizamos, observamos um recuo mínimo para 89,1% — apenas 1,2 pontos percentuais abaixo do pico. Isso nos leva a uma conclusão que vai além da hipótese original: em jogos suficientemente engajantes para reter seus usuários por centenas de horas, a satisfação permanece elevada mesmo em estágios avançados de uso. O efeito de saturação simplesmente não se manifesta com a intensidade esperada, o que sugere que o cansaço com um título é muito menos comum do que a ausência de engajamento inicial. Para desenvolvedores, essa descoberta reforça a importância de mecânicas de retenção de médio prazo como driver primário de satisfação.

[FIGURA 1 — Barras: taxa de recomendação por categoria de tempo de jogo (Baixo / Médio / Alto / Saturação)]

Figura 1. Taxa de recomendação positiva por faixa de tempo de jogo acumulado.

3.2. H2A — Faixa de Preço e Satisfação

A segunda hipótese, em sua primeira dimensão, previa que jogos com preços mais elevados gerariam maior insatisfação em decorrência do aumento das expectativas do consumidor proporcional ao investimento financeiro. A análise confirma essa hipótese de forma pronunciada na extremidade superior da distribuição de preços, mas revela um comportamento intermediário mais complexo do que o previsto.

As faixas Barato ($< \$10$) e Médio ($\$10\text{--}\30) apresentaram taxas muito próximas e elevadas — 87,2% e 88,3%, respectivamente —, com a faixa Médio sendo inclusive a de maior taxa entre todos os títulos pagos. Esse resultado contraria a hipótese de uma relação monotonicamente decrescente e sugere que jogos de preço intermediário, faixa onde se concentram muitos títulos independentes de qualidade consolidada, tendem a oferecer a melhor combinação de custo-benefício percebido. A faixa Caro ($\$30\text{--}\60) já apresenta uma queda para 83,9%, sinalizando que expectativas mais elevadas começam a pesar sobre a avaliação final.

A queda mais acentuada, no entanto, ocorre na faixa Premium ($> \$60$): apenas 63,9% de recomendação positiva, uma diferença de 24,4 pontos percentuais em relação à faixa Médio. Esse resultado é, na nossa leitura, a descoberta quantitativamente mais sólida de todo o projeto. Os testes Z aplicados sobre os 200.000 registros retornaram $z = -11,53$ ($p \approx 0$) para Premium versus Barato e $z = -12,59$ ($p \approx 0$) para Premium versus Médio — valores que indicam que essa diferença está completamente fora do domínio do acaso. A interpretação que oferecemos é direta: consumidores que pagam acima de \$60 por um jogo constroem expectativas de qualidade, conteúdo e duração proporcionalmente elevadas, e quando o produto não atende integralmente a essas expectativas — o que é estatisticamente mais provável dado que a fronteira de qualidade percebida aumenta com o preço — a propensão à avaliação negativa cresce de forma não-linear.

*[FIGURA 2 — Barras: taxa de recomendação por faixa de preço
(Barato / Médio / Caro / Premium)]*

Figura 2. Taxa de recomendação positiva por faixa de preço.

3.3. H2B — Efeito dos Descontos Promocionais

A segunda dimensão da hipótese H2 previa que jogos adquiridos com desconto apresentariam maior satisfação, pois o preço reduzido diminuiria as expectativas do consumidor. O resultado que encontramos foi o oposto: jogos adquiridos pelo preço cheio apresentaram taxa de 87,1%, marginalmente superior à de 86,1% observada para jogos em promoção.

É importante qualificar essa descoberta adequadamente. A diferença de 1,0 ponto percentual é estatisticamente significativa com 200.000 registros ($z = -2,97$; $p = 0,003$), mas sua relevância prática é limitada dado o tamanho absoluto diminuto do efeito. O achado mais instrutivo, porém, está na comparação com o experimento preliminar de 20.000 amostras, no qual esse mesmo teste retornou $p = 0,984$ — completamente não significativo. Esse contraste ilustra de forma didática o impacto do poder estatístico: com amostra insuficiente, um efeito real mas pequeno simplesmente desaparece no ruído amostral.

Quanto à direção do efeito, a explicação mais plausível que identificamos é o fenômeno de *seleção adversa*: usuários que adquirem jogos em promoção frequentemente compram títulos que não estavam em sua lista de prioridades, ou seja, jogos nos quais o interesse inicial é menor do que nos títulos comprados pelo preço cheio. Isso resulta em menor engajamento e, conseqüentemente, em menor probabilidade de avaliação positiva. Esse mecanismo se conecta diretamente com o que observamos em H1 — menor engajamento leva a menor tempo de jogo, que por sua vez é o preditor mais forte de insatisfação.

3.4. H3 — Jogos Gratuitos versus Pagos

A terceira hipótese previa que títulos gratuitos apresentariam taxa de recomendação superior, pois a ausência de risco financeiro na aquisição reduziria as expectativas do consumidor. Os dados revelaram o contrário: jogos pagos registraram taxa de 87,1% contra apenas 80,1% dos gratuitos — uma diferença de 7,0 pontos percentuais desfavorável ao modelo Free-to-Play.

Esse resultado inicialmente nos surpreendeu, mas encontramos uma explicação que consideramos convincente ao examinar a composição do catálogo de jogos gratuitos na Steam. O modelo Free-to-Play abrange uma variedade muito ampla de títulos: de um lado, grandes produções de alta qualidade com monetização por cosméticos opcionais; de outro, uma quantidade expressiva de títulos de qualidade marginal desenvolvidos com o objetivo de monetização agressiva via microtransações ou mecânicas predatórias de pay-to-win. Essa heterogeneidade faz com que a média de satisfação nos jogos gratuitos seja puxada para baixo pelos títulos de baixa qualidade. A categoria de jogos pagos, por outro lado, realiza uma filtragem natural: desenvolvedores que cobram por um produto têm incentivos diretos para garantir um nível de qualidade que justifique o preço, criando uma seleção implícita de qualidade mínima que não existe no catálogo gratuito.

4. Modelos Avaliados

A escolha dos métodos foi orientada por dois critérios simultâneos: desempenho preditivo e interpretabilidade dos resultados. O objetivo final do projeto não é meramente maximizar métricas de classificação em um conjunto de teste isolado, mas apoiar decisões gerenciais concretas e comunicar insights a diferentes públicos. Com esse propósito, selecionamos três modelos de complexidades escalonadas.

A **Regressão Logística** foi escolhida como baseline por constituir o método canônico para classificação binária com variáveis preditoras mistas, combinando fundamentação probabilística sólida e interpretabilidade intuitiva dos coeficientes. No

Tabela 2. Síntese dos Testes Estatísticos (Z para diferença entre proporções)

Comparação	Est. Z	p-valor	Significância	Direção
Desconto vs. Preço Cheio	-2,97	0,003	Sig. $\alpha < 0,01$	Desconto $\rightarrow$ menor satisfação
Premium (> \$60) vs. Barato	-11,53	≈ 0	Altamente sig.	Premium muito menor
Premium (> \$60) vs. Médio	-12,59	≈ 0	Altamente sig.	Premium muito menor

nosso contexto, os coeficientes quantificam diretamente a contribuição de cada atributo ao log-odds de recomendação positiva. A implementação utilizou regularização L2 com parâmetro $C = 1$ e solver *lbfgs*. Sua limitação estrutural mais relevante para este projeto é a incapacidade de capturar relações não-lineares — especialmente a queda abrupta na faixa Premium e o padrão de U-invertido de H1 —, que os modelos baseados em árvores capturam naturalmente.

O **Random Forest** foi selecionado por ser um método ensemble robusto e consolidado para dados tabulares, capaz de modelar relações não-lineares e interações entre variáveis sem que seja necessário especificá-las manualmente. O duplo mecanismo de aleatorização — bootstrap de amostras e seleção aleatória de features por nó (`max_features='sqrt'`) — confere alta resistência ao overfitting e reduz a variância das predições. A implementação utilizou 100 estimadores com critério Gini e semente fixada para reprodutibilidade.

O **XGBoost Classifier** representa o estado da arte em aprendizado de máquina tabular. Diferentemente do Random Forest, que trata cada árvore como independente, o XGBoost constrói o modelo sequencialmente: cada nova árvore é guiada pelo gradiente dos erros residuais do ensemble parcialmente construído, o que tende a resultar em maior poder preditivo. Adicionalmente, o XGBoost incorpora regularizações L1 e L2 diretamente em seu objetivo de otimização e foi configurado com `scale_pos_weight` ajustado ao desbalanceamento de classes da amostra. Sua integração nativa com a biblioteca SHAP é especialmente relevante para os objetivos interpretativos do projeto, permitindo explicar não apenas quais variáveis são globalmente importantes, mas como cada variável impacta a predição de cada instância individualmente.

5. Métricas e Estratégia de Validação

O **F1-Score** foi definido como métrica primária de avaliação por constituir a média harmônica entre Precisão e Recall. A escolha é especialmente adequada aqui porque o dataset apresenta desbalanceamento de classes em favor da classe positiva (taxas agregadas de recomendação positiva de 80–90%), o que tornaria a Acurácia uma métrica enganosa: um modelo trivial que previsse sempre a classe majoritária poderia atingir alta Acurácia sem qualquer capacidade preditiva real sobre os

casos negativos. A média harmônica penaliza fortemente qualquer modelo que negligencia uma das duas dimensões, incentivando equilíbrio entre Precisão e Recall. A **AUC-ROC** foi utilizada como métrica complementar, avaliando a qualidade do ranqueamento probabilístico independentemente do limiar de decisão — propriedade especialmente valiosa em aplicações de sistemas de recomendação, onde o objetivo frequente é ranquear itens por probabilidade de satisfação.

A estratégia de validação combina dois níveis: um **holdout estratificado** de 20% (40.000 registros), mantido completamente isolado durante o desenvolvimento e acessado uma única vez na avaliação final; e **validação cruzada estratificada** com $k = 5$ folds sobre os 80% restantes (160.000 registros), com métricas reportadas como média $\pm$ desvio padrão entre folds. Esse duplo nível é necessário porque quando modelos competem entre si com múltiplos conjuntos de validação cruzada, existe o risco de overfitting ao conjunto de validação — o holdout elimina esse risco ao introduzir um conjunto genuinamente nunca visto durante o desenvolvimento.

6. Resultados e Discussão

6.1. Desempenho Comparativo dos Modelos

Os resultados consolidados de holdout e validação cruzada são apresentados na Tabela 3.

Tabela 3. Comparação Consolidada das Métricas (* = modelo selecionado para produção)

Modelo	Holdout F1	Holdout AUC	CV F1 (média $\pm$ dp)	CV AUC (média $\pm$ dp)
Reg. Logística	0,8133 (81,3%)	0,6707 (67,1%)	0,8150 $\pm$ 0,0022	0,6713 $\pm$ 0,0013
Random Forest	0,8897 (89,0%)	0,6620 (66,2%)	0,8883 $\pm$ 0,0016	0,6541 $\pm$ 0,0011
XGBoost *	0,9241 (92,4%)	0,7037 (70,4%)	0,9237 $\pm$ 0,0004	0,6970 $\pm$ 0,0003

O XGBoost consolidou-se como o modelo de melhor desempenho, superando os demais em ambas as métricas. A melhoria de +11,1 pontos percentuais de F1 em relação à Regressão Logística e de +3,4 pontos em relação ao Random Forest é substancial e justifica sua escolha como modelo de produção. Além da performance absoluta, o aspecto que mais nos chamou atenção foi a estabilidade do XGBoost: seu desvio padrão de apenas 0,0004 no F1 da validação cruzada é três vezes menor do que o já baixo desvio do Random Forest (0,0016), indicando que o modelo aprende padrões genuinamente generalizáveis e não se apoia em peculiaridades de partições específicas dos dados. A convergência quase perfeita entre a média de CV (0,9237) e o holdout (0,9241) — uma diferença de apenas 0,0004 — confirma a ausência de overfitting mesmo sendo o modelo de maior complexidade dentre os três avaliados. Esse resultado é atribuído à combinação entre o mecanismo de boosting sequencial e as regularizações L1/L2 embutidas no objetivo de treinamento.

Um resultado aparentemente paradoxal merece atenção: o Random Forest apresenta AUC inferior à Regressão Logística (0,662 versus 0,671), apesar de ter F1-Score consideravelmente superior (0,890 versus 0,813). A explicação reside na forma como cada modelo produz suas probabilidades: a Regressão Logística gera

probabilidades naturalmente calibradas pela função sigmoide, distribuídas ao longo de todo o espectro $[0, 1]$; o Random Forest, por sua vez, produz probabilidades como média de votos binários de suas árvores individuais, o que tende a comprimir os valores ao redor de 0,5 e reduz o poder discriminativo ao longo de múltiplos limiares — exatamente o que a AUC mede. No limiar padrão de 0,5, porém, o RF discrimina muito melhor, o que explica seu F1 elevado.




Figura 3. Curvas ROC: comparação da qualidade probabilística dos três modelos.

6.2. Feature Importance e Análise SHAP

A análise das importâncias das variáveis nos três modelos revelou padrões complementares e, em alguns aspectos, surpreendentemente divergentes entre as abordagens. No Random Forest, a variável **hours** lidera com $\approx 35\%$ de importância, mas a surpresa fica com a segunda e terceira posições: **products** ($\approx 31\%$) e **reviews** ($\approx 17\%$), ambas variáveis de perfil do usuário — não do jogo. Esse resultado indica que o histórico comportamental do usuário na plataforma como um todo é altamente preditivo de sua propensão a recomendar, sugerindo que usuários mais engajados com a Steam em geral também tendem a ser avaliadores mais generosos ou mais criteriosos de forma consistente.

Na Regressão Logística, o padrão é radicalmente diferente: as dummies de **playtime_category** dominam, com coeficientes de $\approx 1,85$ para Saturação, $\approx 1,78$ para Alto e $\approx 1,22$ para Médio. Isso reflete exatamente o que observamos na análise de H1: no espaço linear, a faixa de tempo de jogo é o preditor mais poderoso de satisfação.

No XGBoost, o padrão é intermediário, mas com uma redistribuição significativa: **hours** lidera com $\approx 32\%$, mas agora **price_final** sobe para segundo lugar com $\approx 21\%$ — uma posição muito mais proeminente do que nos outros modelos. Essa elevação é diretamente atribuível à capacidade do gradient boosting de capturar a relação não-linear abrupta entre preço e satisfação: a queda dramática na faixa Premium é exatamente o tipo de padrão que árvores de decisão detectam com facilidade por meio de divisões binárias, mas que uma Regressão Logística só consegue aproximar indiretamente.

[FIGURA 4 — Barras horizontais: Feature Importance do XGBoost (por gain ou cover)]

Figura 4. Feature Importance do XGBoost Classifier.

A análise SHAP, aplicada sobre o XGBoost, fornece a camada interpretativa mais granular e é onde os achados das hipóteses se traduzem em contribuições individuais às predições. A variável **hours** exibe o padrão mais amplo e informativo: instâncias com baixo valor concentram-se na região negativa do eixo SHAP (entre -2 e 0), confirmando que poucas horas de jogo reduzem sistematicamente a probabilidade predita de recomendação; instâncias com alto valor deslocam-se para a região positiva, reforçando a relação de H1 diretamente no nível das predições individuais. Para **price_final**, valores elevados contribuem negativamente — com os casos extremos da faixa Premium claramente deslocados para a esquerda do espectro. A variável **is_free** apresenta impacto predominantemente negativo, coerente com a refutação de H3. Esse conjunto de padrões SHAP não apenas confirma os achados das hipóteses, mas os interpreta em um nível de granularidade que permite entender como cada fator age sobre a predição de um usuário específico em um contexto específico.

[FIGURA 5 — SHAP beeswarm plot: distribuição dos valores SHAP por feature, coloridos pelo valor da variável]

Figura 5. Análise SHAP: contribuição individual de cada variável às predições do XGBoost.

7. Conclusão

7.1. Síntese das Descobertas

Os experimentos realizados neste projeto produziram um conjunto de descobertas que, tomadas em conjunto, oferecem uma visão bastante coerente sobre o que determina a satisfação de usuários na Steam. A hipótese H1 foi **parcialmente confirmada**: o mecanismo de experiência insuficiente é robusto e pronunciado — a

diferença de 22,4 pontos percentuais entre as categorias Baixo e Médio é a maior observada em qualquer comparação do projeto —, mas o efeito de saturação esperado simplesmente não se materializa com a intensidade que prevíamos, com um recuo de apenas 1,2 pontos percentuais entre Alto e Saturação.

A hipótese H2A foi **confirmada para a faixa Premium**, com evidência estatisticamente sólida de que jogos acima de \$60 apresentam taxa de recomendação de apenas 63,9% — o mesmo nível da categoria Baixo de playtime. A hipótese de relação monotonicamente decrescente entre preço e satisfação, porém, não se sustenta nas faixas intermediárias. A hipótese H2B foi **refutada**: descontos estão associados a menor satisfação, ainda que por uma margem pequena, o que inverte completamente a intuição original. A hipótese H3 também foi **refutada**: jogos gratuitos apresentam satisfação inferior à de jogos pagos, resultado que interpretamos como reflexo da heterogeneidade qualitativa do catálogo Free-to-Play e da filtragem implícita de qualidade que o modelo pago impõe.

7.2. Recomendações e Implicações Práticas

As descobertas deste projeto têm implicações práticas diretas para diferentes atores do mercado. Do ponto de vista dos **sistemas de recomendação**, os resultados justificam a adoção do XGBoost como módulo central, com ganho de 11,1 pontos percentuais de F1 sobre o baseline linear. Mais do que a métrica em si, o que o modelo captura é relevante: ele aprende que o tempo acumulado de jogo é o sinal mais forte de satisfação futura, o que abre a possibilidade de sistemas que ajustem recomendações dinamicamente com base no histórico de engajamento do usuário com títulos similares.

Para **desenvolvedores e publishers**, a descoberta sobre a faixa Premium é especialmente crítica: 36,1% dos usuários que pagam mais de \$60 não recomendam o produto, o que representa uma taxa de insatisfação duas vezes maior do que a observada nas faixas intermediárias. Estratégias de lançamento gradual via Early Access podem funcionar como mecanismo de calibração de expectativas antes do preço final ser fixado. Para **gestores de marketing**, a descoberta sobre descontos é contraintuitiva mas clara: políticas promocionais devem ser avaliadas por métricas de conversão de vendas, não pela expectativa de que produzirão avaliações mais positivas — essa expectativa não encontra suporte nos dados.

7.3. Limitações e Trabalhos Futuros

O estudo apresenta limitações que devem ser consideradas na interpretação dos resultados. A subamostragem a 200.000 registros pode sub-representar padrões específicos de nichos de mercado. O modelo não incorpora a dimensão temporal dos dados, o que impede analisar como a satisfação evolui ao longo do ciclo de vida de um título. Os metadados textuais foram explorados apenas via contagem de tags, sem qualquer análise semântica do conteúdo das descrições ou das próprias avaliações. Por fim, o viés de engajamento inerente à publicação de avaliações — usuários que avaliam não são uma amostra aleatória de todos os usuários — não foi modelado explicitamente.

Como direções prioritárias para continuidade do trabalho, identificamos: a expansão para o dataset completo de 41 milhões de registros; o refinamento via

tuning de hiperparâmetros por busca bayesiana; a incorporação de features semânticas derivadas de NLP sobre as descrições e avaliações textuais; a validação temporal completa com divisão treino-teste por data; e a exploração de Graph Neural Networks para capturar relações estruturais entre usuários e jogos que os modelos tabulares não conseguem representar adequadamente.